

KASTAMONU ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI



Çalışma ADI

2. Final Ödev raporu

Ad Soyad

Serap HERKİLOĞLU

Danışmanı:

Doç. Dr. Kemal AKYOL

KASTAMONU- 2025

(18 HAZİRAN 2025)

Özet

Deney iki olarak yürütölen alıřmada, inme tahmini iin yapay sinir ağı kullanılarak iki farklı deneysel strateji uygulanmıřtır: Growing denPruning'e ve Pruning 'den Growing'e olmak üzere alıřmalar deęerlendirilmiřtir. Kaggle'den seilen inme veri setinin ham veri performansında iyi olmaması nedeni ile Dropout, EarlyStopping ve ModelCheckpoint gibi dőzenleme teknikleri kullanılmıřtır. Modelin bařarımı; %99 doęruluk olarak ilk alıřma iin beklenenin őstőnde ve tatmin edici olarak alınmıřtır. Karıřıklık matrisi ve sınıf bazlı metriklerle deęerlendirildięinde ise ařırı őęrenme gibi istenmeyen durumlar tespit edilmemiřtir. Elde edilen sonulardan yola ıkarak, őzellikle Growing'den Pruning'e gitme stratejisinin daha yőksek doęruluk ve sınıf ayırma bařarısı saęladığını gőstermiřtir.

1. Giriř

İnme, dőnya genelinde őnde gelen őlőm nedenlerinden biridir ve erken tanı bőyők őnem tařımaktadır [1-2]. İnme , beyne giden zayıf kan akıřının hőcre őlőmőne neden olduęu tıbbi bir durumdur [3]. nmenin bařlıca belirtileri arasında vőcudun bir tarafında hareket kaybı veya hissizlik, konuřma ya da anlama gőlőęő, bař dőnmesi ve bir tarafta gőrme kaybı yer alır [4]. Tanı ve teřhis olarak ise kolay tanı konuđu gőrőlmőřtőr. Geliřen tıbbi tanı tekniklerinin en popőleri olan Yapay zeka, őzellikle derin őęrenme yőntemleri, tıbbi tanılarda kullanılmak őzere umut vadetmeye devam ettięi iin bu hastalık iin sonular merak edilerek seilmiřtir. Bu alıřmanın amacı, inme tahmini iin kullanılan bir sinir ağı modelinde bőyőtme (growing) ve budama (pruning) tekniklerinin etkisini incelemektir.

2. Literatőr Taraması

Yapay sinir aęları, insan beyninin bilgi iřleme yeteneęinden esinlenilerek geliřtirilmiř, ok katmanlı yapay őęrenme modelleridir. Biyolojik verileri őzerindeki kullanımı gőnőmőzde ok yaygınlařmıřtır . Saęlık alanında yapılan alıřmalarda, Yapay sinir aęların; inme teřhisi, diyabet tahmini, kalp rahatsızlıklarının sınıflandırılması ve gőrőntő tabanlı hastalık analizlerinde yőksek doęruluk oranlarına ulařtığı bildirilmiřtir [5-6]. İnme, dőnya őzerinde nőrolojik olarak gelen őlőm ve sakatlık nedenleri arasında sayılmaktadır [1-3]. Erken teřhis ve mődahale, hastanın yařam kalitesini ciddi řekilde dięer nőrolojik hastalıklar gibi olumlu etkileyeceęi dőřőnőlmőřtőr. Bu nedenle, son yıllarda yapay zekâ yőntemlerinin, őzellikle yapay sinir aęlarının, inme tahmini ve teřhisinde sıka kullanıldıęı da aıktır [7]. Birok alıřma, Yapay sinir aęlarının inme riskinin tahmin edilmesinde bařarılı sonular verdięini kaynaklar ile sunulmuřtur. Bunların arasında, Gupta ve ekibi (2025), saęlık gemiři, yař, cinsiyet, hipertansiyon, kalp hastalıęı ve vőcut kitle indeksi gibi parametreleri ieren bir veri kőmesi őzerinde yapay sinir aęlarını uygulayarak %95,04 őzerinde doęruluk elde etmiřtir [8]. Bu alıřma, erken tarama sistemlerinin geliřtirilebilmesi aısından őnemli bir katkı sunmaktadır. Daha geliřmiř derin sinir ağı yapıları (Deep Neural Networks, DNN) kullanılarak yapılan arařtırmalarda, inme riski tařıyan bireylerin sınıflandırılması, Yapay sinir ağı modellerinin dięer

klasik yöntemlere (ör. Lojistik Regresyon, Karar Ağaçları) göre daha yüksek F1 skorları sunduğunu da ortaya koymuştur. Buna örnek olarak Li ve sekiz kişilik ekibinin (2023) “Machine learning in the prediction of post-stroke cognitive impairment: a systematic review and meta-analysis” adlı çalışması ilgi çekmektedir. İnme için, görüntü verilerine dayalı inme teşhisinde de derin yapay sinir ağlarında yaygın şekilde kullanılmaktadır. Bilgisayarlı Tomografi (BT) ve Manyetik Rezonans Görüntüleme (MRG) verileri üzerinden eğitilen konvolüsyonel sinir ağları (CNN’ler), iskemik ve hemorajik inme ayrımı gibi karmaşık sınıflandırma görevlerinde kullanılmaktadır. Bu çalışmanın diğerlerinden ayırıcı yanı ise son yıllarda, model karmaşıklığını azaltmak için önerilen pruning tekniği ve bunun yanı sıra model kapasitesini artırmak için kullanılan growing yöntemini de uygulanmış olmasıdır. Model tasarımı yapılırken bu farklı yollarla ilerlenecek olan Yapay sinir ağlarının insan beyni gibi büyüttüğünde mi yoksa budadığında mı daha iyi sonuçlar verdiği tespit edilebilir olacaktır. Kaggle’den açık olarak alınan ve kullanılan inme gibi dengesiz veri setine [10] sahip sınıflarda, bu yöntemlerin başarımlarındaki etkisi araştırılması için çalışma yürütülmüş olacaktır.

3. Materyal ve Yöntem

Kaggle platformunda bulunan ve sağlık verilerini içeren “stroke-prediction-dataset” adlı açık kaynak veri setidir . Veri seti, hastaların demografik bilgileri, sağlık durumları ve inme geçirme durumlarını içermektedir [10]. Eksik veriler medyan değerleriyle doldurulmuş, kategorik değişkenler daha iyi işlem yapabilmesi için One-Hot Encoding yöntemi ile sayısal forma dönüştürülmüştür. Model eğitim ve testi için veri seti, %80 eğitim ve %20 test olacak şekilde “stratify” parametresi kullanılarak bölünmüştür. Özelliklerin farklı ölçeklerde olması model performansını olumsuz etkileyebileceğinden, eğitim ve test verileri Standartlaştırmasına dikkat edilmiştir. Model, TensorFlow kütüphanesi ve Keras API kullanılarak oluşturulmuştur. İlk katman giriş katmanı olup, "relu" aktivasyon fonksiyonu kullanılmıştır. Takip eden gizli katmanlarda da "relu" aktivasyonu ve %30 oranında Dropout uygulanarak aşırı öğrenme (overfitting) önlenmiştir. Çıkış katmanında ise ikili sınıflandırma problemi için sigmoid aktivasyon fonksiyonu tercih edilmiştir. Modelin derlenmesinde optimizasyon algoritması olarak Adam, kayıp fonksiyonu olarak binary crossentropy seçilmiştir. Model eğitimi sırasında aşırı öğrenmeyi önlemek ve en iyi ağırlıkları kaydetmek amacıyla EarlyStopping ve ModelCheckpoint callback fonksiyonları kullanılmıştır. EarlyStopping, önerilen kaybı 5 epoch boyunca iyileşmezse eğitimi duracaktır. Bunun diğer yapay sinir ağları modellerinden ayıcı olarak iki deneysel senaryo uygulanmıştır:


- **Growing → Pruning:** Katman sayısı küçük başlayıp giderek azalan (32, 16) yapı ile model oluşturulup eğitilmiştir.

- **Pruning → Growing:** Daha derin ve geniş (128, 64, 32) katmanlardan oluşan model eğitilmiştir.

Her iki deneyde model 50 epoch olarak eğitim verisinin %20’si doğrulama için kullanılarak eğitilmiştir.


4. Deneyisel Çalışma Çıktılar

Grafik 1, budama (pruning) sonrası büyüme (growing) aşamasında, modelin eğitim (training) ve doğrulama (validation) kayıplarının (loss) değişimini sergilemektedir. Bu aşamanın başlangıcında, eğitim kaybı hızla düşüş eğilimi göstererek kısa sürede stabilize olurken, doğrulama kaybı nispeten sabit kalmakta veya minimal düzeyde artış sergilemektedir. Bu gözlem, büyüme stratejisi boyunca eğitim kaybının zamanla azalmasına karşın doğrulama kaybının ya durağanlaşması ya da hafifçe yükselmesiyle tutarlıdır. Bu durum, budama stratejisinin aşırı uyumu (overfitting) engelleme kapasitesine dair güçlü bir kanıt sunmaktadır.




Grafik-1: Pruning → Growing giden çalışma

Grafik 2 ise, aynı budama sonrası büyüme sürecinde modelin doğruluk (accuracy) oranlarının seyrini ortaya koymaktadır. Eğitim doğruluğu hızlı bir artış göstererek kısa sürede yüksek bir seviyede kararlılık kazanmakta, bu da modelin öğrenme sürecinin etkinliğini teyit etmektedir. Doğrulama doğruluğu ise, özellikle büyüme evresi boyunca kayda değer bir artış göstererek oldukça yüksek seviyelerde istikrarlı bir performans sergilemektedir. Her iki grafikten elde edilen bulgular, budama stratejisinin modelin karmaşıklığını azaltarak aşırı uyumu önlediğini ve buna rağmen yüksek doğruluk oranlarının sürdürülebildiğini açıkça göstermektedir. Bu sonuçlar, uygun bir budama ve büyüme stratejisinin genel model performansını optimize etmede kritik bir rol oynadığını desteklemektedir.




Grafik-2: Growing → Pruning'e giden çalışma

Grafik 3'de iki deneyde elde edilen karışıklık matrisleri, modelin sınıflandırma performansını ortaya koymaktadır. "Growing → Pruning" ve "Pruning → Growing" sıralamalarıyla gerçekleştirilen deneylerde, modelin özellikle "inme yüksek risk" sınıfı üzerinde veri yetersizliği olmasına rağmen başarılı olduğu söylenebilir. "Düşük risk" oldukça başarılı bir performans sergilediği, yüksek doğruluk ve düşük hata oranlarıyla desteklenmektedir. "inme olmayan" sınıfında da benzer biçimde yüksek doğruluk elde edilmiş olmakla birlikte, az sayıda yanlış pozitif tahmin gözlemlenmiştir. Sentetik verilerin burada modelin karmaşıklığını ne kadar etkilediği sonucuna varılmıştır.




Grafik-3: Karmaşıklık Matrisi

Bu sorunu çözmek amacıyla, **SMOTE (Synthetic Minority Over-sampling Technique)** yöntemi kullanılmıştır. Bu teknik, sınıflar arasında daha adil bir temsil sağlayarak modelin hem çoğunluk hem de azınlık sınıflarına karşı duyarlılığını artırmayı sağlamıştır. Grafik 4'de model çıktıları bize bunu açıkça göstermektedir.




Grafik-4:Veri Dengesizliği Olmayan Model


Grafik 5'in her iki deneyde elde edilen karışıklık matrisleri, yüksek ve düşük risk sınıflarının sınıflandırma doğruluğu yüksek seviyededir ve bu sınıflarda karışıklık matrisi sonuçları başarılı tahminlere işaret etmektedir. Ancak, orta risk sınıfı için sınıflandırma performansı görece düşük olup, bu sınıfa ait örneklerin bir kısmı yanlış sınıflara atanmıştır. Bu durum, orta risk sınıfının diğer sınıflara kıyasla model tarafından daha zor ayrıştırıldığını göstermektedir. Dolayısıyla, model performansını artırmak için özellikle orta risk sınıfına yönelik iyileştirme stratejilerinin geliştirilme yoluna ileriki süreçte gidilebileceği düşünülmektedir.




Grafik-5: Karmaşıklık Matrisi



Grafik-6: Sınıflara Göre kesinlik Karşılaştırması



Grafik-7: Sınıflara Göre Duyarlılık



Grafik-8: Sınıflara Göre F1 Skoru Karşılaştırması

Modelin genel doğruluğu %0,99, her iki sınıfı da büyük oranda başarılı bir şekilde ayırt edebildiğini göstermektedir. Özellikle sağlık alanında uygulanan sınıflandırma modellerinde, doğru pozitif (TP) ve doğru negatif (TN) tahmin oranlarının yüksek olması, erken teşhis, yanlış alarm oranının düşürülmesi ve klinik karar destek sistemlerinin güvenilirliği açısından kritik öneme sahiptir.

5. Tartışma

Model iyileştirme tekniklerinin karşılaştırılması, Büyüme (Growing) ve Budama (Pruning) stratejilerinin performans üzerindeki farklı dinamiklerini ortaya koymuştur. Büyüme, hızlı öğrenme ve yüksek doğruluk artışı sağlarken; Budama, başlangıçta daha yavaş ilerlese de, zamanla istikrarlı sonuçlar ve daha az karmaşık, dolayısıyla daha iyi genelleştirme yeteneğine sahip modeller sunmaktadır. Kayıp ve doğruluk seviyeleri benzer olsa da, model karmaşıklığı ve aşırı uyum riski açısından Budama, optimizasyon için daha avantajlı bir yaklaşım olarak öne çıkacağı düşünülmektedir.

6. Sonuçlar

Deneyisel çalışmada, farklı model iyileştirme stratejilerinin (Büyüme ve Budama) model performansı üzerindeki etkilerini kapsamlı bir şekilde ortaya koymaya çalışılmıştır. Kayıp ve doğruluk oranları incelendiğinde, Büyüme stratejisi öğrenme sürecinde hızlı bir adaptasyon ve performans artışı sergilerken, Budama stratejisi daha kademeli ancak istikrarlı bir iyileşme sunmuş, aynı zamanda model karmaşıklığını azaltarak genelleştirme yeteneğini potansiyel olarak artırmıştır. Her iki yaklaşım da eğitim sonunda benzer genel performans seviyelerine ulaşmıştır. Model başarısı %99-%95 arasında bize uygulamanın verimli sonuçlar sunduğunu göstermiştir.

Karışıklık matrisi analizleri ise modelin sınıf bazındaki performansında önemli farklılıkları gözler önüne sermiştir. Model, çok sınıflı olarak tespitinde önemli zorluklar yaşamış ve bu sınıfa ait örnekleri doğru bir şekilde tanımlamıştır. Bu durum, modelin belirli sınıflara karşı önyargılı olabileceğine veya veri setindeki sınıf dengesizliğine giderilmesinin daha iyi sonuçlar sunacağını işaret etmektedir.

Sonuç olarak, her ne kadar her iki strateji de genel doğrulukta benzer bitiş noktalarına ulaşsa da, model karmaşıklığını azaltma ve aşırı uyumu engelleme potansiyeli göz önüne alındığında Budama stratejisi, daha genellenebilir ve optimize edilmiş modeller geliştirmek için potansiyel olarak daha avantajlı bir seçenek sunmaktadır. Gelecek çalışmalarda, sınıf dengesizliklerinin giderilmesi için fark yöntemlerle ve modelin her iki sınıftaki performansını eşitlemeye yönelik değişik yaklaşım stratejiler incelenmesi daha iyi olacaktır.

7.Kaynak

- [1] Utku, U. (2007). İnme Tanımı, Etyolojisi, Sınıflandırma ve Risk Faktörleri. *Turkish Journal of Physical Medicine & Rehabilitation/Turkiye Fiziksel Tip ve Rehabilitasyon Dergisi*, 53.
- [2] Bonita, R. (1992). Epidemiology of stroke. *The Lancet*, 339(8789), 342-344.
- [3] Stroke, W. C. A. (2003). What is a Stroke?. *Southwest Highway*, 708, 1100.
- [4] Donnan, G. A., Davis, S. M., Chambers, B. R., Gates, P. C., Hankey, G. J., McNeil, J. J., ... & Tuck, R. R. (1996). Streptokinase for acute ischemic stroke with relationship to time of administration. *Jama*, 276(12), 961-966.
- [5] Rajkomar, A., Oren, E., Chen, K., Dai, A. M., Hajaj, N., Hardt, M., ... & Dean, J. (2018). Scalable and accurate deep learning with electronic health records. *NPJ digital medicine*, 1(1), 18.
- [6] Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *nature*, 542(7639), 115-118.
- [7] Feigin, V. L., Stark, B. A., Johnson, C. O., Roth, G. A., Bisignano, C., Abady, G. G., ... & Hamidi, S. (2021). Global, regional, and national burden of stroke and its risk factors, 1990–2019: a systematic analysis for the Global Burden of Disease Study 2019. *The Lancet Neurology*, 20(10), 795-820.
- [8] Gupta, A., Mishra, N., Jatana, N., Malik, S., Gepreel, K. A., Asmat, F., & Mohanty, S. N. (2025). Predicting stroke risk: an effective stroke prediction model based on neural networks. *Journal of Neurorestoratology*, 13(1), 100156.
- [9] Li, X., Chen, Z., Jiao, H., Wang, B., Yin, H., Chen, L., ... & Qin, D. (2023). Machine learning in the prediction of post-stroke cognitive impairment: a systematic review and meta-analysis. *Frontiers in Neurology*, 14, 1211733.
- [10] Kaggle Stroke Dataset: <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>
- [11] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- [12] Srivastava, N. et al. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research*.
- [13] Prechelt, L. (1998). Early Stopping - But When? *Neural Networks: Tricks of the Trade*.